



Projektdokumentation

19th Century London Data

Erstellt von

Leonie Abels, Amirreza Ahmadi Darani, Aziz Klebleyev, Bjarne Möller,
Franz Müller, Xuan-Loc Tran

Data Analytics
Prof. Dr. Jil Klünder
17. Mai 2026

Inhaltsverzeichnis

Kapitel 1

Einleitung und Fragestellung

Die vorliegende Dokumentation beschreibt die Durchführung und die Ergebnisse unseres Datenanalyseprojekts im Rahmen des Moduls Data-Analytics. Gemäß der im Kurs behandelten Phasen liegt der Fokus auf der Definition einer Fragestellung, der methodischen Datenbeschaffung sowie der Anwendung moderner statistischer Verfahren zur Ableitung von Handlungsempfehlungen.

1.1 Armut im viktorianischen London

Während des 19. Jahrhunderts versuchte der Soziologe Charles Booth, Ausmaß und Ursachen der Armut in East-London zu erfassen. Sein Ansatz basierte hierbei auf systematischer Erfassung und Analyse von Daten. Die hierbei entstandene Monografie *“Life and Labour of the People in London”* lieferte neben statistische Tabellen auch detaillierte, farbcodierte Landkarten, welche die soziale Schichtung der Stadt visualisierten. Hierzu führte er folgende Klassifikation innerhalb der Arbeitergruppen ein:

Tabelle 1.1: Charles Booths Klassifikation sozialer Schichten

Class	Description	Category	Alias
A	Lowest class	very poor & semi-criminal	Lowest Class
B	Casual earnings	very poor & semi-criminal	Casual Earnings
C	Intermittent earnings	poor	Irregular Earnings
D	Small regular earnings	poor	Regular Minimum
E	Regular standard earnings	comfortable	Ordinary Earnings
F	Higher class labour	comfortable	Highly Paid Work
G	Lower middle class	well to do	Lower Middle
H	Upper middle class	well to do	Upper Middle

Die Besonderheit unseres Projektes liegt in der Datengrundlage: Da keine digitalen Datensätze verfügbar waren, wurden die Datensätze manuell persistiert, um sie später gem. unseres Vorlesungsinhaltes in Python zu verarbeiten.

1.2 Motivation und Relevanz

Die Motivation für dieses Mini-Projekt entspringt der Notwendigkeit, komplexe sozioökonomische Zusammenhänge nicht nur deskriptiv zu erfassen, sondern durch analytische Statistik tiefere Einblicke in strukturelle Risikofaktoren zu gewinnen.

Methodische Motivation: Moderne Analyse historischer Daten

Hauptmotivation war für uns die Überlegung ob bestimmte Berufssektoren oder Familienkonstellationen systematisch benachteiligt waren und ob dies Rückschlüsse auf die Entstehung sozialer Ungleichheit zulässt. Aus Sicht der Data Analytics besteht der besondere Reiz darin, moderne statistische Verfahren auf einen Datensatz anzuwenden, der ursprünglich mit weit einfacheren Mitteln ausgewertet wurde. Hauptaugenmerk liegt hierbei darauf:

- Sämtliche Vorbedingungen für statistische Tests (wie die Normalverteilung) kritisch zu hinterfragen und zu dokumentieren.
- Durch fortgeschrittene Methoden wie die robuste multiple Regression Erkenntnisse zu generieren, die über die rein deskriptiven Zahlen der Originalquellen hinausgehen.
- Relevante Risikofaktoren zu messen, anstatt wahllos verfügbare Datenpunkte zu korrelieren.

Nutzen für Dritte

Die Beantwortung unserer Fragestellung liefert einen Mehrwert für Historiker, Soziologen und Datenanalysten gleichermaßen. Durch die Paraphrasierung der Ergebnisse wird deutlich, welche Faktoren tatsächlich belastbare Prädiktoren für Armut waren. Dies ermöglicht eine präzise Bewertung historischer Lebensumstände und dient als Fallstudie für den Umgang mit nicht-idealen, realen Datensätzen in der modernen Wissenschaft.

1.3 Verfeinerung der Fragestellung

Unsere ursprüngliche Fragestellung lautet: „*Welche Faktoren bestimmten die Armut im London des 19. Jahrhunderts?*“.

Der Mehrwert moderner Methoden

Zur Zeit der Datenerhebung durch Booth waren Verfahren der inferenzstatistischen Modellierung wie die multiple lineare Regression oder nicht-parametrische Signifikanztests entweder noch nicht entwickelt oder aufgrund mangelnder Rechenkapazitäten nicht anwendbar. Booth konnte Korrelationen visuell identifizieren, jedoch nicht deren statistische Signifikanz unter Berücksichtigung von Störvariablen (Multikollinearität) prüfen. Unser Projekt nutzt diese modernen Verfahren, um die historischen Daten auf ihre mathematische Belastbarkeit zu untersuchen.

Konkretisierung und Hypothesenbildung

Um die grobe Fragestellung operabel zu machen, haben wir sie in drei konkrete Untersuchungsebene unterteilt:




Abbildung 1.1: Grafische Verfeinerung der Fragestellung gemäß Phase 1

1.4 Zielsetzung des Berichts

In der vorliegenden Ausarbeitung werden alle Projektphasen, von der Definition der Fragestellung über die Datenverarbeitung bis hin zur Modellbildung, detailliert beschrieben und begründet. Im Fokus steht dabei die Beantwortung der verfeinerten Fragestellung. Über die rein deskriptive Darstellung hinaus verfolgt dieser Bericht das Ziel, durch inferenzstatistische Methoden belastbare Erkenntnisse über soziale Abhängigkeiten und strukturelle Benachteiligungen zu gewinnen.

Damit soll verdeutlicht werden, welchen praktischen Nutzen die Beantwortung der Fragestellung für die Einordnung historischer Lebensumstände sowie für das Verständnis allgemeiner Armutsmechanismen bietet.

Kapitel 2

Methodik

In diesem Kapitel wird der Prozess der Datenakquise und -aufbereitung detailliert beschrieben. Da für die Fragestellung keine modernen digitalen Datensätze zur Verfügung standen, musste eine Brücke zwischen historischer Dokumentation und moderner Datenanalyse geschlagen werden.

2.1 Beschreibung der Datenquelle

Als primäre Datenquelle dient das Werk „*Life and Labour of the People in London*“ von Charles Booth (1886–1903). Die Analyse stützt sich auf die detaillierten Tabellen, in denen die Bevölkerung Londons nach Berufsfeldern (Sections) und sozialen Klassen (A–H) kategorisiert wurde. Jede Zeile der Originaltabellen enthält Informationen über:

- Die **Berufsklasse** (z. B. Labour, Artisans, Dealers).
- Demografische Merkmale wie **Heads of Families**, **Wives** und **Children** unter 15 Jahren.
- Die Verteilung der Personen auf die **sozialen Klassen A bis H**.

2.2 Problematik unklarer oder ungenauer Daten

Es lässt sich anmerken, dass Booths gelieferten Daten teils ungenau sind. So werden an einigen Stellen Schätzungen vorgenommen, die nicht als solche ausgezeichnet sind.

2.3 Datenerhebung und manuelle Transkription

Die Datenerhebung erfolgte durch die manuelle Übertragung der Informationen aus digitalen Scans der Originalseiten in ein maschinenlesbares Format

(CSV). Dieser Prozess umfasste:

- **Digitalisierung:** Übertragung der gedruckten Tabellen in CSV-Dateien für jeden untersuchten Borough.
- **Qualitätssicherung:** Abgleich der übertragenen Werte mit den Originalwerten zur Vermeidung von Übertragungsfehlern.
- **Umgang mit historischen Begriffen:** Beibehaltung der originalen Bezeichnungen, um die historische Authentizität zu wahren.

2.4 Eingesetzte Tools und Infrastruktur

Für die Verwaltung und Verarbeitung der Daten wurden folgende Werkzeuge genutzt:

- **GitHub:** Versionskontrolle und Zusammenarbeit im Team. Die Nutzung von Branches (z. B. `trial-Branch`) ermöglichte eine parallele Bearbeitung von Skripten und Datensätzen.
- **Python (Pandas):** Zentrale Bibliothek für die Datenmanipulation. Pandas wurde gewählt, da es eine effiziente Harmonisierung unterschiedlicher Tabellenstrukturen und eine automatisierte Berechnung neuer Metriken ermöglicht.

2.5 Vorgehen bei der Datenzusammenführung (Data Merging)

Ein entscheidender Schritt war die Kombination der einzelnen Distrikt-Tabellen zu einem Gesamtdatensatz (`merged_london_data.csv`). Das Vorgehen gliederte sich in:

1. **Standardisierung:** Vereinheitlichung der Spaltennamen, da die Originalscans teilweise leicht variierende Schreibweisen (z. B. „Hheads of Famlies“ vs. „Hheads of Families“) aufwiesen.
2. **Konkatenation:** Zusammenführung der Daten aus den Boroughs Bethnal, Green, Hackney, Mile End Old Town, Poplar, Shoreditch, Stepney und St. George’s-in-the-East.
3. **Aggregatbildung:** Integration der Zusammenfassungen auf Borough-Ebene (`classes_boroughs_total.csv`) und Berufsebene (`professions_total.csv`) zur Validierung der Gesamtsummen.

Kapitel 3

Datenverarbeitung und Vorverarbeitung

In dieser Phase wurden die digitalisierten Rohdaten bereinigt und transformiert, um eine präzise Beantwortung der Forschungsfragen zu ermöglichen. Ein wesentlicher Bestandteil war die Überprüfung statistischer Voraussetzungen, um die Belastbarkeit der späteren Modelle sicherzustellen.

3.1 Datenbereinigung / Data Cleaning

Bevor die eigentliche Analyse beginnen konnte, mussten die aggregierten Daten aus den verschiedenen Boroughs harmonisiert werden.

- **Standardisierung:** Spaltenbezeichnungen wurden vereinheitlicht, um Inkonsistenzen zwischen den Teildatensätzen zu beseitigen. Dies umfasst z.B. die Korrektur von „Heads of Famlies“ zu „Heads of Families“.
- **Umgang mit Fehlwerten:** Da leere Felder in den historischen Tabellen oft das Nichtvorhandensein einer Gruppe signalisierten, wurden *NaN*-Werte (Not-a-Number) durch Nullen ersetzt, um mathematische Berechnungen zu ermöglichen.
- **Deskriptive Vorstudie:** Es wurde eine deskriptive Statistik durchgeführt, um ein Gefühl für die Verteilungen und mögliche „Ausreißer-Berufe“ zu erhalten.

Hieraus ließ sich folgender Boxplot für die Armutsraten erstellen:




Abbildung 3.1: Boxplot Armutsklassen

3.2 Feature Engineering: Konstruktion von Metriken

Um die Fragestellung nach Risikofaktoren operationalisierbar zu machen, wurden aus den Rohdaten neue Variablen berechnet:

- **Poverty Rate:** Um die Armut messbar zu machen, wurde die Quote der Klassen A bis D im Verhältnis zur Gesamtbevölkerung einer Sektion berechnet:

$$poverty_rate = \frac{A + B + C + D}{Total}$$

- **Kids per Household:** Um die demografische Belastung zu erfassen, wurde die Anzahl der Kinder pro Haushaltsvorstand ermittelt (*Children / Heads of Families*).

3.3 Statistische Voraussetzungsprüfung

Ein zentraler Aspekt der Qualitätssicherung war die Überprüfung der Normalverteilung.

- **Shapiro-Wilk-Test:** Der Test auf die *poverty_rate* ergab eine Test-Statistik von 0,8229 und einen p-Wert von $9,11 \times 10^{-19}$.
- **Ergebnis:** Da der p-Wert weit unter der Schwelle von 0,05 liegt, wurde die Nullhypothese einer Normalverteilung abgelehnt. Die Stichprobe ist somit nicht-gaussisch (not Gaussian).

3.4 Methodische Konsequenzen

Aufgrund der fehlenden Normalverteilung wurden die Analysepläne angepasst, um die Validität der Ergebnisse nicht zu gefährden:

- **Nicht-parametrische Tests:** Für Gruppenvergleiche wurde der Kruskal-Wallis-Test anstelle einer ANOVA gewählt.
- **Korrelationen:** Die Zusammenhänge wurden mittels Spearman-Rangkorrelation anstelle von Pearson untersucht. Grund ist, dass die Spearman-Rangkorrelation robust gegenüber nicht-normalverteilten Daten ist.
- **Modell-Anpassung:** Für die Regression wurde ein transformiertes Modell (Log-Transformation) in Betracht gezogen, um die Residuen-Eigenschaften zu verbessern.




Abbildung 3.2: spearman correlation

Kapitel 4

Datenanalyse und Modellbildung

In dieser Phase erfolgte die tiefergehende Untersuchung der Forschungsfrage nach den Risikofaktoren für Armut. Basierend auf den Erkenntnissen der Vorverarbeitung wurden nicht-parametrische Tests für Gruppenvergleiche und multivariate Regressionsmodelle eingesetzt.

4.1 Explorative Analyse der Berufsgruppen

Um festzustellen, ob sich das Armutsrisiko zwischen den verschiedenen sozialen Sektionen signifikant unterscheidet, wurde ein Gruppenvergleich durchgeführt. Da die Voraussetzung der Normalverteilung verletzt war, wurde der **Kruskal-Wallis-Test** als nicht-parametrische Alternative zur ANOVA gewählt.

- **Ergebnis:** Der Test lieferte eine Teststatistik von $H = 68,15$ bei einem p-Wert von $4,47 \times 10^{-08}$.
- **Interpretation:** Die Nullhypothese, dass die Armutsrate über alle Sektionen hinweg gleich verteilt ist, wurde abgelehnt. Es existieren somit hochsignifikante Unterschiede im Armutsrisiko zwischen den Berufsgruppen.

4.2 Multivariate Modellierung der Risikofaktoren

Um den Einfluss mehrerer Faktoren gleichzeitig zu isolieren, wurde eine multiple lineare Regression (OLS) berechnet. Hierbei wurden zwei Modelle verglichen, um die bestmögliche statistische Güte zu erreichen.

Modellvergleich und Residuendiagnostik

Ein zentrales Gütekriterium für Regressionsmodelle ist die Normalverteilung der Residuen.

- **Basis-Modell:** Die Residuen des ursprünglichen Modells wiesen eine starke Abweichung von der Normalverteilung auf ($p = 4,59 \times 10^{-10}$).
- **Transformiertes Modell:** Durch eine Log-Transformation ($\log 1p$) der Zielvariable *poverty_rate* konnte die Verteilung der Residuen signifikant verbessert werden (Teststatistik: 0,9842; $p = 0,001$).

Aufgrund dieser Ergebnisse wurde das transformierte Modell für die finale Interpretation gewählt, da es die statistischen Voraussetzungen besser erfüllt.

Robustheit der Schätzung

Um die Ergebnisse jenseits rein deskriptiver Zahlen abzusichern, wurde die Kovarianz-Matrix des Modells mit **robusten Standardfehlern (Typ HC3)** berechnet. Dieses Verfahren schützt die Signifikanztests vor Verzerrungen durch Heteroskedastizität, was angesichts der historischen Datenqualität eine notwendige methodische Absicherung darstellt.

Zusammenfassung der Modellergebnisse

Das finale Modell erreicht ein bereinigtes Bestimmtheitsmaß ($Adj.R^2$) von 0,192. Dies bedeutet, dass ca. 19,2% der Varianz der Armutsrate durch die einbezogenen Faktoren erklärt werden können. Sämtliche Koeffizienten wurden auf ihre Signifikanz geprüft, um belastbare Aussagen über die Risikofaktoren treffen zu können.




Abbildung 4.1: regression-qqplot




Abbildung 4.2: regression-residuals




Abbildung 4.3: regression-qqplot2

Kapitel 5

Ergebnisse und Interpretation

In diesem Kapitel werden die Ergebnisse der statistischen Modellierung präsentiert und im Hinblick auf die Forschungsfrage nach den Risikofaktoren für Armut interpretiert. Die Analyse basiert auf dem transformierten Regressionsmodell mit robusten Standardfehlern (HC3), welches die höchste statistische Belastbarkeit aufweist.

Identifikation zentraler Risikofaktoren

Die Regressionsanalyse identifiziert zwei primäre strukturelle Risikofaktoren, die einen signifikanten positiven Einfluss auf die Armutsrate haben:

- **Berufsstatus „Labour“:** Mit einem Koeffizienten von 0,2339 ($p < 0,001$) stellt die Zugehörigkeit zur Gruppe der unqualifizierten Tagelöhner das größte Armutsrisiko dar. Dies bestätigt Booths deskriptive Beobachtungen auf mathematischer Ebene.
- **Weibliche Haushaltsvorstände:** Sektionen mit einem hohen Anteil an weiblichen Vorständen weisen einen signifikanten Koeffizienten von 0,1583 ($p = 0,004$) auf. Dies deutet darauf hin, dass Haushalte ohne männlichen Verdiener (oft bedingt durch Arbeitsunfälle oder Verwitwung) im viktorianischen London besonders vulnerabel waren.

Schutzfaktoren und soziale Stabilität

Im Gegensatz dazu konnten deutliche Schutzfaktoren identifiziert werden, die mit einer signifikanten Verringerung der Armutsrate korrelieren:

- Berufe im Sektor **Salaried** (Angestellte) sowie im Bereich **Refreshments** (Gastgewerbe) weisen stark negative Koeffizienten auf (z.

B. $-0,2185$, $p < 0,001$). Regelmäßige Einkommen und eine feste Anstellung waren somit die effektivsten Mittel zur Armutsprävention.

Demografie vs. Struktur

Ein wesentliches Finding der Analyse ist die fehlende Signifikanz der demografischen Variablen im multiplen Modell:

- **Kinderzahl:** Entgegen der ursprünglichen Hypothese liefert die Variable *kids_per_household* ($p = 0,414$) keinen signifikanten zusätzlichen Erklärungsbeitrag zur Armutsrate, sobald der Berufsstatus kontrolliert wird.
- **Alleinstehende Männer:** Auch das *unmarried_ratio* ($p = 0,359$) ist statistisch nicht signifikant.

Dies deutet darauf hin, dass Armut im 19. Jahrhundert primär ein **strukturelles Problem des Arbeitsmarktes** und weniger ein rein demografisches Problem der Haushaltsgröße war.

Güte und Belastbarkeit des Modells

Das Modell erklärt ca. 23,8% der Varianz der Armutsrate ($R^2 = 0,238$). Während dies für sozialwissenschaftliche Daten ein solider Wert ist, bleibt ein Großteil der Varianz durch Faktoren ungeklärt, die nicht in den historischen Tabellen erfasst wurden, z.b. individuelle Gesundheitszustände oder lokale Mietpreise. Es muss zudem kritisch angemerkt werden, dass es sich um **Korrelationen**, nicht zwingend um Kausalitäten handelt.

Kapitel 6

Ableitbare Handlungsempfehlungen

Ableitbare Handlungsempfehlungen

Basierend auf den Analyseergebnissen lassen sich folgende Empfehlungen für eine fiktive Sozialpolitik der damaligen Zeit formulieren:

- **Stabilisierung prekärer Arbeitsverhältnisse:** Da ungelernte Tagelöhner das höchste Risiko trugen, wäre eine Transformation hin zu regulären Beschäftigungsverhältnissen eine effektive Maßnahme gewesen.
- **Gezielte Unterstützung:** Da Haushalte mit weiblichen Vorständen eine signifikant höhere Armutsrate aufwiesen, hätte es spezifischer Unterstützungssysteme bedarft.
- **Strukturelle statt demografische Fokussierung:** Maßnahmen sollten eher auf Arbeitsmarktreformen und Mindestlöhne abzielen als auf die Kontrolle der Familiengröße, da letztere statistisch einen geringeren Erklärungsbeitrag zur Armut leistete.

Fazit und Reflexion

Dieses Mini-Projekt demonstriert einen Nutzen moderner statistischer Verfahren für die Interpretation historischer Daten. Trotz der Einschränkung, dass die Daten ursprünglich nicht für die moderne Analyse erhoben wurden und keine Normalverteilung aufwiesen, konnten durch aktuelle Verfahren belastbare Aussagen getroffen werden. Der Prozess von der manuellen Datenerfassung bis zur Modellbildung verdeutlicht, dass eine kritische Prüfung der Vorbedingungen essenziell ist, um Fehlinterpretationen zu vermeiden.

Anhang A

Appendix

Tabelle A.1: OLS Regression Results

Variable	Coef.	Std. Err.	z	P> z
Intercept	0.2497	0.059	4.231	0.000
Artisans	0.0116	0.034	0.344	0.731
Assistants	-0.0791	0.051	-1.552	0.121
Dealers	0.0126	0.055	0.229	0.819
Females	0.1583	0.055	2.877	0.004
Labour	0.2339	0.066	3.558	0.000
Locomotion	-0.0943	0.043	-2.177	0.029
Manufacture	-0.1222	0.060	-2.035	0.042
Manufacture &c.	-0.1393	0.068	-2.037	0.042
Manufacturers	-0.0232	0.144	-0.161	0.872
No work	0.1001	0.102	0.986	0.324
Other	-0.1176	0.196	-0.600	0.548
Other wages	-0.0908	0.046	-1.955	0.051
Refreshment	-0.2003	0.048	-4.201	0.000
Refreshments	-0.2185	0.032	-6.746	0.000
Salaried	-0.1898	0.042	-4.526	0.000
Salaried &c.	-0.1398	0.049	-2.872	0.004
Total	-0.0166	1.152	-0.014	0.988
kids_per_household	-0.0220	0.027	-0.817	0.414
unmarried_ratio	0.4120	0.449	0.917	0.359

Model Information	Value
Dependent Variable	log_poverty_rate
R-squared	0.238
Adjusted R-squared	0.192
F-statistic	16.67
Prob (F-statistic)	5.42×10^{-37}
No. Observations	331
Df Residuals	311
Df Model	19
Covariance Type	HC3
Durbin-Watson	1.651
Jarque-Bera (JB)	15.796
Prob (JB)	0.000371
Cond. No.	63.9

Notes: Standard Errors are heteroscedasticity robust (HC3).

Tabelle A.2: Statistical Test Results

Test	Statistic	p-value	Conclusion
Shapiro-Wilk Test for Normality on poverty_rate	0.8229	9.1119×10^{-19}	The sample does not look Gaussian (reject H_0)
Kruskal-Wallis Test on poverty_rate across Section_Class	68.1526	4.4751×10^{-8}	Significant difference between sections (reject H_0)
Shapiro-Wilk Test for Normality on Regression Residuals (Base Model)	0.9423	4.5952×10^{-10}	Residuals do not look Gaussian (reject H_0)
Shapiro-Wilk Test for Normality on Regression Residuals (Transformed Model)	0.9842	1.0606×10^{-3}	Residuals do not look Gaussian (reject H_0)

Model Comparison: The transformed model using $\log(1 + x)$ better fulfills the statistical prerequisites, particularly the normality assumption of residuals.